



DATA SCIENCE & VISUALISATION

Le cycle de valorisation de la donnée

Un manuel méthodologique et technique conçu pour structurer l'apprentissage théorique et le passage à l'échelle des projets analytiques modernes.

ÉDITION

Syllabus Premium 2026

NIVEAU D'EXPERTISE

Intermédiaire à Avancé

VALIDATION

Crédits ECTS Éligibles

Sommaire

Ce manuel pédagogique est conçu comme une référence pour les professionnels et étudiants. Il articule les fondements analytiques et les meilleures pratiques d'ingénierie visuelle.

Chapitre 1 : Introduction à la Data Science	Page 3
Chapitre 2 : Collecte & Préparation des Données (Data Wrangling)	Page 4
Chapitre 3 : Analyse Statistique Descriptive & Exploration	Page 5
Chapitre 4 : Introduction au Machine Learning	Page 6
Chapitre 5 : Principes Fondamentaux de la Visualisation	Page 7
Chapitre 6 : Outils Pratiques & Data Storytelling	Page 8

PRÉREQUIS TECHNOLOGIQUES

Pour exploiter pleinement ce cours, il est fortement conseillé de disposer de notions de base en programmation **Python** (notamment les bibliothèques Pandas et NumPy) et d'une compréhension globale du langage d'interrogation de bases de données **SQL**.

1. Introduction à la Data Science

La science des données s'est imposée comme une discipline pivot du XXIème siècle. Elle permet d'extraire de la valeur d'une matière première omniprésente mais complexe : la donnée brute.

1.1 LA CONVERGENCE INTERDISCIPLINAIRE

La Data Science n'est pas une compétence isolée, mais l'interaction harmonieuse de trois expertises :

1. MATHÉMATIQUES & MODÉLISATION

Comprendre la structure sous-jacente des données à travers l'algèbre linéaire, le calcul différentiel, les probabilités et la statistique inférentielle.

2. INGÉNIERIE LOGICIELLE

Savoir écrire un code propre, performant et réutilisable pour automatiser l'ingestion, la transformation et le calcul distribué sur des volumes imposants.

3. EXPERTISE MÉTIER

Savoir traduire un problème opérationnel complexe (ex: baisse de marge, attrition client) en une série de questions algorithmiques solvables.

CONCEPT CLÉ : LE CYCLE DE VIE CRISP-DM

Le standard international **CRISP-DM** rappelle que la science des données est cyclique : l'évaluation d'un modèle de Machine Learning amène souvent à reformuler la compréhension métier originelle.

2. Collecte & Préparation des Données

L'adage informatique "*Garbage in, Garbage out*" trouve tout son sens en Data Science. Un modèle hautement sophistiqué ne produira jamais de bons résultats s'il est alimenté par des données corrompues, bruitées ou mal préparées.

2.1 LE DATA WRANGLING OU L'ART DE NETTOYER

Le processus de préparation des données comporte quatre étapes de transformation systématiques :

- **L'Ingestion** : Importation sécurisée de flux hétérogènes (fichiers CSV, bases de données relationnelles SQL, flux temps réel Kafka).
- **L'Imputation** : Traitement des valeurs manquantes. La suppression pure et simple est déconseillée car elle réduit l'échantillon ; on lui préfère souvent l'imputation par valeurs centrales ou par modèles prédictifs locaux.
- **Le Traitement des Anomalies (Outliers)** : Écartement ou lissage des valeurs s'éloignant exagérément de la distribution normale (via l'écart interquartile).

2.2 EXEMPLE D'IMPLÉMENTATION INDUSTRIELLE

Ci-dessous, un exemple de script robuste utilisant `pandas` pour le traitement des anomalies et l'encodage des variables catégorielles :

```
import pandas as pd
import numpy as np

# Ingestion robuste et filtrage
df = pd.read_csv("dataset_ventes.csv")

# Élimination des anomalies sur la colonne 'montant' (Seuil IQR > 1.5)
q1 = df['montant'].quantile(0.25)
q3 = df['montant'].quantile(0.75)
iqr = q3 - q1
seuil_sup = q3 + 1.5 * iqr

df = df[df['montant'] <= seuil_sup]

# Encodage One-Hot des variables catégorielles
df_encoded = pd.get_dummies(df, columns=['categorie_client'], drop_first=True)
```

3. Analyse Statistique Descriptive

Avant d'activer des modèles d'apprentissage automatique, l'analyse exploratoire permet de faire parler visuellement et numériquement les données pour en comprendre les lois de distribution.

3.1 LES MÉTRIQUES FONDAMENTALES

Pour résumer une variable aléatoire continue, on étudie sa tendance centrale et son niveau de dispersion.

MESURE DE L'ÉCART-TYPE (DISPERSION)

L'écart-type est l'indicateur universel de la volatilité ou de l'étalement de vos mesures autour de leur moyenne théorique :

$$\sigma = \sqrt{[\sum (x_i - \mu)^2 / N]}$$

Où μ représente la moyenne de l'échantillon et N l'effectif global observé.

3.2 CORRÉLATION LINÉAIRE DE PEARSON

Le coefficient de corrélation linéaire de Pearson r permet d'évaluer l'intensité du lien linéaire entre deux variables.

PLAGE DU COEFFICIENT R	INTENSITÉ DE LA RELATION	IMPACT MODÉLISATION
0.7 à 1.0 (ou -0.7 à -1.0)	Relation très forte	Excellents prédicteurs mais risque de colinéarité si utilisés ensemble.
0.3 à 0.7 (ou -0.3 à -0.7)	Relation modérée	Intérêt certain pour des modèles de régression multivariés.
0.0 à 0.3 (ou 0.0 à -0.3)	Relation faible à nulle	Indique l'absence d'une relation linéaire directe (mais une relation non linéaire est possible).

4. Introduction au Machine Learning

Le Machine Learning consiste à concevoir des modèles capables d'extraire des lois mathématiques sous-jacentes à partir d'exemples observés, afin de réaliser des prédictions ou des segmentations automatisées.

4.1 TAXONOMIE DES ALGORITHMES

APPRENTISSAGE SUPERVISÉ (SUPERVISED LEARNING)

Le modèle dispose d'un historique étiqueté. Il associe des caractéristiques d'entrée X à une cible Y .

- **Régression** : Prédiction de valeurs continues (ex: température, chiffre d'affaires).
- **Classification** : Affectation à une classe discrète (ex: détection de transactions frauduleuses).

APPRENTISSAGE NON SUPERVISÉ (UNSUPERVISED LEARNING)

Aucune cible n'est fournie. Le but est de cartographier la structure intrinsèque des données.

- **Clustering (ex: K-Means)** : Regroupement automatique de profils d'utilisateurs en sous-segments homogènes.

4.2 LE FLÉAU DU SURAPPRENTISSAGE (OVERFITTING)

Un modèle trop complexe risque de mémoriser les spécificités et les bruits du jeu d'entraînement au lieu de généraliser les concepts sous-jacents. Pour évaluer la performance réelle sur de nouvelles données, l'évaluation se fait via une validation croisée (*Cross-Validation*).

VALIDATION DES MODÈLES DE CLASSIFICATION

L'évaluation ne repose pas uniquement sur le taux de bonne prédiction globale (Accuracy). On utilise l'indice **F1-score**, qui calcule la moyenne harmonique entre la **Précision** (proportion d'alertes positives réelles) et le **Rappel** (capacité à détecter l'intégralité des positifs réels).

5. Principes de la Visualisation

La Data Visualisation (DataViz) n'est pas un art purement esthétique. C'est l'application scientifique de la psychologie cognitive et de la perception humaine au traitement de l'information.

5.1 LES PROPRIÉTÉS PRÉ-ATTENTIVES

Avant même que notre cerveau ne conceptualise l'information de manière logique, nos yeux analysent les contrastes physiques en moins de 250 millisecondes. Les plus importants sont :

- **La position spatiale** : L'attribut le plus précis pour l'œil humain (utilisé dans les nuages de points).
- **La longueur** : Base d'évaluation de nos graphiques en barres.
- **La couleur (Teinte et Saturation)** : À réserver en priorité pour catégoriser des groupes ou surligner une anomalie critique.

5.2 MATRICE DE SÉLECTION VISUELLE

Le tableau ci-dessous synthétise la règle de choix graphique universelle pour garantir l'impact cognitif de vos rapports :

TYPE D'ANALYSE	GRAPHIQUE OPTIMAL	BONNE PRATIQUE DE DESIGN
Séries temporelles	Graphique en courbes (Line chart)	Toujours positionner le temps sur l'axe horizontal (X). Limiter à 4 courbes.
Comparaison nominale	Graphique en barres (Bar chart)	Ordonner les barres de la plus grande à la plus petite pour faciliter la lecture.
Distribution de valeurs	Boîte à moustaches (Boxplot)	Idéal pour représenter visuellement la médiane, les quartiles et les outliers.

6. Outils & Data Storytelling

Le but ultime de l'analyse est de transformer une donnée brute en décision d'affaires ou d'ingénierie. C'est ici qu'intervient le **Data Storytelling** : l'art de concevoir un récit structuré autour des visuels clés.

6.1 LE FRAMEWORK DE NARRATION ANALYTIQUE

Pour qu'une visualisation mène à l'action, elle doit intégrer trois dimensions complémentaires :

1. **Le Contexte (The Context)** : Expliquer clairement la situation de départ et la problématique à résoudre.
2. **Le Point de Friction (The Climax)** : Utiliser des contrastes graphiques pour matérialiser l'anomalie ou l'opportunité découverte.
3. **La Recommandation (The Call to Action)** : Proposer des pistes de résolution concrètes étayées par l'analyse statistique.

6.2 L'ÉCOSYSTÈME TECHNOLOGIQUE MODERNE

LIBRAIRIES DE DÉVELOPPEMENT PYTHON / R

Seaborn / Plotly / Shiny : Outils de prédilection des ingénieurs data et des statisticiens pour l'exploration ad hoc et la génération de graphiques dynamiques web-compatibles.

PLATEFORMES DE BUSINESS INTELLIGENCE D'ENTREPRISE

Power BI & Tableau : Logiciels leaders pour le déploiement de tableaux de bord interactifs d'entreprise. Ils s'intègrent nativement aux entrepôts de données (Data Warehouses) et gèrent automatiquement les mises à jour planifiées de données de production.

SYNTHÈSE FINALE

Devenir performant en **Data Science & Visualisation** demande de maîtriser la rigueur du code, l'exactitude des mathématiques et la clarté de la communication. Ce cours pose les fondations théoriques et méthodologiques pour vous accompagner sur ces trois piliers d'excellence.